



Inteligencia Artificial

TRABAJO PRÁCTICO N° 3

Redes Neuronales

Docentes:

- Mg. Díaz, Santiago R.
- AS. Lopez, Joaquin

Alumnos:

- Marioni, Alex
- Ledesma, Alejo

Fecha de entrega:

11/06/2026

Índice

Índice	2
Introducción	3
Selección de dataset	3
Arquitectura del modelo base y evaluación	3
Entrenamiento y curvas de aprendizaje	3
Matriz de Confusión	4
Justificación y Elección de la Métrica Crítica	4
Overfitting	4
Estrategia para Forzar el Sobreajuste	4
Hiperparámetros	5
Tasa de aprendizaje	5
Batch Size	6
Hidden Units	6
Dropout	6

Introducción

En este reporte exponemos el diseño, entrenamiento y evaluación de una red neuronal artificial del tipo Perceptrón Multicapa, orientada a resolver un problema de clasificación binaria. Para el desarrollo del proyecto, utilizamos Keras, empleando su arquitectura de Modelo Secuencial.

Selección de dataset

Elegimos el dataset "[mstz/breast](#)" de Hugging Face. Este Dataset cuenta con registros médicos analizados mediante biopsias, en total 9 características que evalúan del 1 al 10. La variable **is_cancer** define el diagnóstico. Un tumor maligno es 1, y 0 para valor benigno.

Respecto a los datos nulos del mismo, se tomó la decisión de calcular la media de cada columna para rellenar el dato faltante/vacío/nulo. Además, al dividir los datos para entrenar y evaluar se utilizó una estrategia de estratificación, para asegurar la proporción correcta.

Y en lo que a escalamiento se refiere, se utilizó una estandarización estadística mediante StandardScaler, para tener una media de 0 y una varianza de 1.

Arquitectura del modelo base y evaluación

Capa de entrada: Recibe las variables previamente procesadas

Primera capa oculta: 16 neuronas con función de activación ReLU.

Dropout: 0.2, para no depender siempre las mismas neuronas.

Segunda capa oculta: también 8 neuronas.


Capa de salida: contiene 1 neurona con función de activación Sigmoide. De forma que la salida sea en un rango continuo entre 0 y 1.

Entrenamiento y curvas de aprendizaje

El modelo utilizó **epochs=100**, con **32 muestras**. Y un 20% del conjunto de entrenamiento se reservó de forma interna para la validación durante el proceso

Al analizar el gráfico de las curvas de entrenamiento generado por el script, se pueden extraer las siguientes observaciones analíticas:

- Loss: En un principio, los errores, tanto en la validación como en el entrenamiento fueron algo común, y a medida que pasaron las épocas (alrededor de la 20) el sistema se fue estabilizando y mejorando de manera estable.
- Accuracy: para la precisión el caso es similar, en un principio, como es lógico el sistema fallaba para con el comienzo de las épocas ir mejorando poco a poco.



Matriz de Confusión

Al mapear los resultados en la matriz de confusión, se obtuvo lo siguiente:

- **Verdaderos Negativos (Benignos correctamente identificados):** 86 muestras.
- **Verdaderos Positivos (Malignos correctamente identificados):** 47 muestras.
- **Falsos Positivos (Casos benignos clasificados erróneamente como malignos):** 4 muestras.
- **Falsos Negativos (Casos malignos clasificados erróneamente como benignos):** 0 muestras.

Justificación y Elección de la Métrica Crítica

En este contexto, la métrica crítica seleccionada para describir el éxito del sistema es el Recall. En el diagnóstico de cáncer de mama, cometer un **Falso Positivo** implica someter a un paciente sano a estudios adicionales, sin embargo, cometer un **Falso Negativo** significa enviar a un paciente con un tumor maligno a su hogar sin tratamiento, poniendo en riesgo directo su vida.


Dado que el modelo base alcanzó un **Recall perfecto de 1.0 (100%)** al registrar 0 Falsos Negativos en la matriz de confusión, se concluye que la red neuronal cumple con el criterio de seguridad clínica esencial, complementado además con un alto equilibrio general reflejado en su métrica F1-Score.

Overfitting

Para analizar y evidenciar esto, se realizó el archivo **exp_02_overfitting.py**.

Estrategia para Forzar el Sobreajuste

- Se setó ***n_small*** = 60
- Se incrementaron las capas ocultas a 256, 256 y 128 neuronas.
- ***Dropout*** = 0.0
- 300 ***epochs***.



Esto

dio como resultado la clara evidencia de memorización por parte del sistema, dando un Loss de 0 en Train, ya que el sistema memorizó, y cuando se lo ponía a prueba solía fallar mucho más que el modelo anterior.


Así también se ve esa exactitud con los ajustes entrenados, memorizados y por ende un 100% de acierto, aunque pierde en el validador, con un poco menos.

Hiperparámetros

A continuación, se exponen los resultados y el análisis teórico de los cuatro hiperparámetros estudiados:

Tasa de aprendizaje


Se evaluó el comportamiento probando cinco órdenes de magnitud: 3.0, 1e-1, 1e-2, 1e-3 y 1e-5.



Como los gráficos no mienten, podemos ver que en ambos extremos los resultados difieren bastante de la media, dándonos un 3.0 con 0 aprendizaje y en 1e-05, un recall de alrededor del 50%.

Batch Size


Se analizaron cuatro tamaños de lote para la alimentación de datos durante el entrenamiento: 8, 32, 128 y el conjunto completo (546).



En este sentido podemos ver muy poca variación en los resultados dejándonos con la evidencia que el tamaño del lote, en estos casos, no tiene incidencia directa con los distintos parámetros.

Hidden Units


Se modificó la complejidad estructural del Perceptrón Multicapa evaluando cuatro topologías de capas ocultas: una red minimalista de una sola capa (4), la red base (16, 8), una red mediana (64, 32) y una red de gran capacidad de tres capas (256, 128, 64).



Sorprendentemente, podemos ver cómo con solo 4 neuronas obtenemos resultados similares o casi similares a la mayoría.

Dropout

Finalmente, se evaluó el impacto de la técnica de abandono probando cuatro tasas de apagado aleatorio de neuronas: 0.0 (sin dropout), 0.3, 0.6 y un extremo de 0.9



En el gráfico podemos ver como con dropouts inferiores al 0.9, se mantiene bastante estable y los resultados son buenos, pero al obligar al sistema a dropear el 90% de las neuronas, tanto recall como f1 se vuelven casi nulos en comparación a la parametrización anterior.